

Detección de Fraude de Identidad Sintética mediante Análisis de Grafos en Neo4j:

Aplicación de Graph Data Science a Contextos Fintech

Proyecto de Ciencia de Datos

Bases de Datos NoSQL y Análisis de Redes

13 de mayo de 2026

Ashley Yael López Espinoza

Denzel Gael Cruz Prieto

Gustavo Mier Basilio

Pedro Manuel Cardón Carrillo

Salma Annette Rodríguez Muñoz

Resumen

El fraude de identidad sintética representa una de las amenazas más sofisticadas y costosas para las instituciones financieras digitales. A diferencia del robo de identidad convencional, la identidad sintética combina datos reales e inventados para construir perfiles aparentemente legítimos que eluden los controles tradicionales basados en reglas. El presente proyecto propone y documenta un enfoque analítico para la detección de este tipo de fraude mediante el uso de bases de datos de grafos, específicamente Neo4j, complementado con algoritmos de Graph Data Science (GDS). Se modeló el dominio del problema como un grafo de propiedades que captura entidades —personas, solicitudes, dispositivos, cuentas, entre otras— y sus interrelaciones. Sobre este grafo se ejecutaron consultas en Cypher orientadas a detectar patrones de reutilización de atributos, se construyó un score de riesgo compuesto, y se aplicaron algoritmos de detección de comunidades (Louvain) y centralidad de grado. Los resultados demuestran que el enfoque relacional, al explotar la conectividad entre nodos, logra identificar redes coordinadas de fraude que permanecerían invisibles bajo esquemas de análisis tabular tradicional.

Palabras clave: *fraude de identidad sintética, Neo4j, análisis de grafos, Cypher, Graph Data Science, Louvain, detección de fraude, fintech, riesgo crediticio.*

Tabla de Contenidos

Introducción

Justificación del Uso de Grafos

Modelado del Problema

Generación del Dataset Sintético

Construcción del Grafo en Neo4j

Consultas de Detección de Fraude en Cypher

Construcción del Score de Riesgo

Clasificación del Nivel de Riesgo

Análisis con Graph Data Science

Análisis de Redes de Fraude

Interpretación de Resultados

Validación del Modelo

Resultados Obtenidos

Optimización de la Base de Datos: Índices y Nodos Agregados

Dashboard Ejecutivo: Implementación y Visualización

Discusión

Conclusión

Referencias

Introducción

Contexto del Fraude Financiero

El sistema financiero global enfrenta pérdidas billonarias anuales derivadas de distintas modalidades de fraude. Según estimaciones de diversas organizaciones especializadas en seguridad financiera, el fraude digital ha experimentado un crecimiento acelerado a raíz de la digitalización masiva de los servicios bancarios y la proliferación de plataformas fintech. En este contexto, los mecanismos tradicionales de prevención —como la validación documental o la verificación de datos contra listas negras— han resultado insuficientes frente a amenazas más elaboradas y coordinadas.

Entre estas amenazas, el fraude de identidad sintética (FIS) destaca por su complejidad técnica y por la dificultad inherente que representa su detección. A diferencia de modalidades más directas, como el uso ilícito de credenciales robadas, el FIS implica la construcción activa de identidades ficticias mediante la combinación de datos reales —por ejemplo, números de identificación válidos obtenidos de terceros— con información fabricada, como nombres, fechas de nacimiento y domicilios inexistentes o alterados. El resultado es un perfil que, al ser analizado de forma aislada, puede parecer completamente legítimo.

Qué es la Identidad Sintética

La identidad sintética se define como la creación de una persona ficticia mediante la combinación deliberada de información real e inventada, con el propósito de obtener acceso fraudulento a productos o servicios financieros. Este tipo de fraude se distingue conceptualmente del robo de identidad puro, en el que se utiliza la identidad completa de una persona real sin su conocimiento, puesto que en el FIS la identidad no pertenece a ningún individuo existente: es una construcción artificial.

El proceso de construcción de una identidad sintética suele seguir un patrón estructurado. En primer lugar, el defraudador obtiene o genera un número de identificación válido —en el contexto mexicano, podría ser una CURP o RFC legítimos pertenecientes a personas con poca actividad financiera, como menores de edad o adultos mayores—. Posteriormente, combina ese identificador con un nombre ficticio, un domicilio inventado y un número de teléfono desechable. La identidad resultante puede ser utilizada para solicitar créditos, abrir cuentas o realizar transacciones, acumulando un historial crediticio aparente antes de ejecutar el fraude definitivo.

El Problema en el Ecosistema Fintech

Las empresas fintech son especialmente vulnerables al fraude de identidad sintética por varias razones estructurales. En primer lugar, su propuesta de valor se fundamenta en la rapidez y la accesibilidad del proceso de incorporación de clientes (onboarding), lo que presiona los tiempos de verificación y puede llevar a la omisión de controles exhaustivos. En segundo lugar, al operar exclusivamente en canales digitales, carecen de la interacción presencial que —aunque con sus propias limitaciones— añade una capa adicional de verificación. En tercer lugar, la naturaleza distribuida de sus operaciones las expone a patrones de fraude coordinado que pueden ejecutarse simultáneamente desde múltiples puntos geográficos.

El impacto económico no se limita a las pérdidas directas por créditos impagados. El fraude de identidad sintética genera también costos operativos asociados a la investigación de casos, costos regulatorios derivados de incumplimientos en materia de prevención de lavado de dinero (PLD) y costos reputacionales que afectan la confianza de inversores y usuarios legítimos.

Por qué es Relevante este Análisis

La detección temprana del FIS es una prioridad estratégica para cualquier institución financiera que opere en canales digitales. Este proyecto explora una aproximación metodológicamente diferenciada, basada en el análisis de grafos, para identificar patrones de fraude coordinado que los sistemas convencionales no son capaces de detectar. La relevancia del enfoque reside en que, a diferencia de los modelos tabulares, el análisis de grafos permite explotar explícitamente la red de relaciones entre identidades y atributos, revelando estructuras de fraude que solo son visibles cuando se examina el conjunto, no los casos individuales.

Justificación del Uso de Grafos

Limitaciones de las Bases de Datos Relacionales Tradicionales

Las bases de datos relacionales constituyen la columna vertebral de la mayoría de los sistemas de información financiera. Su modelo tabular, basado en filas y columnas organizadas en tablas vinculadas mediante claves foráneas, es extraordinariamente eficiente para operaciones transaccionales y para consultas que involucren conjuntos de datos bien estructurados y de tamaño predecible. Sin embargo, este modelo presenta limitaciones fundamentales cuando el objeto de análisis no son los registros individuales, sino las relaciones entre ellos.

La primera limitación es de naturaleza estructural: en un modelo relacional, las relaciones entre entidades se representan mediante claves foráneas y tablas de unión (join tables). Cuando una consulta requiere atravesar múltiples niveles de relación —por ejemplo, identificar a todas las personas que comparten un dispositivo con alguien que también comparte una IP con un tercero sospechoso— el número de operaciones JOIN crece exponencialmente con la profundidad de la búsqueda. Este fenómeno, conocido como join explosion, degrada dramáticamente el rendimiento de las consultas y las vuelve inviables a partir de cierta profundidad de exploración.

La segunda limitación es de naturaleza conceptual: el modelo relacional no está diseñado para representar ni razonar sobre la topología de una red. No existe un mecanismo nativo para preguntar, por ejemplo, cuántos caminos alternativos conectan dos nodos, cuál es el nodo más influyente dentro de una red, o qué subconjunto de nodos forma una comunidad densamente conectada.

Ventajas del Modelo de Grafo

Un grafo es una estructura matemática compuesta por nodos (vértices) y aristas (relaciones) que conectan pares de nodos. En el contexto de bases de datos, este modelo ofrece ventajas sustanciales sobre el enfoque relacional para problemas de análisis de redes:

- **Traversal eficiente:** Neo4j almacena las relaciones como punteros directos entre nodos, lo que permite recorrer múltiples niveles de relación en tiempo constante por salto, independientemente del tamaño total del grafo. Esto hace posible consultas de profundidad arbitraria sin degradación de rendimiento.
- **Representación natural:** El modelo de grafo mapea directamente la estructura conceptual del dominio. Las personas, los dispositivos, las direcciones IP y los domicilios son nodos; las relaciones entre ellos son aristas.
- **Algoritmos de análisis de redes:** Neo4j GDS proporciona implementaciones optimizadas de algoritmos fundamentales de teoría de grafos —detección de comunidades, centralidad, caminos más cortos, similitud— que pueden ejecutarse directamente sobre los datos sin necesidad de exportarlos a herramientas externas.
- **Flexibilidad del esquema:** El modelo de grafo de propiedades permite añadir o modificar atributos de nodos y relaciones de forma dinámica, sin necesidad de alterar un esquema rígido.

El Fraude como Fenómeno Relacional

La premisa fundamental que justifica el uso de grafos en este proyecto es la siguiente: el fraude de identidad sintética no es un fenómeno de un solo nodo, sino un fenómeno de red. Una identidad sintética individual puede ser indistinguible de una identidad legítima si se examina de forma aislada. Sus atributos —nombre, domicilio, teléfono— pueden parecer coherentes; su comportamiento transaccional puede ser moderado y aparentemente razonable; sus documentos pueden estar aparentemente en orden.

Lo que delata la identidad sintética es su patrón de conexión con otras identidades. Cuando múltiples identidades comparten el mismo dispositivo, la misma IP o el mismo domicilio, esta convergencia de atributos señala la existencia de una infraestructura compartida que no puede explicarse por coincidencia estadística. Es precisamente esta convergencia —invisible en un análisis registro a registro— la que el grafo captura de forma natural y eficiente.

Modelado del Problema

Arquitectura del Grafo de Propiedades

El modelo de datos de este proyecto sigue el paradigma del grafo de propiedades (Property Graph Model), estándar de Neo4j. En este paradigma, tanto los nodos como las relaciones pueden contener un conjunto arbitrario de propiedades clave-valor, lo que permite enriquecer el grafo con información descriptiva sin necesidad de crear tablas auxiliares.

Descripción de las Entidades (Nodos)

El grafo modela diez tipos de entidades, cada una representada como un tipo de nodo con su etiqueta y conjunto de propiedades:

Entidad	Descripción y propiedades
Persona	Entidad central. Propiedades: id_persona, nombre, apellido_paterno, apellido_materno, fecha_nacimiento, curp, rfc, es_fraude.

Solicitud	Registro de solicitud de crédito o apertura de cuenta. Propiedades: id_solicitud, fecha_solicitud, canal, estatus, score_inicial.
Telefono	Número telefónico declarado. Propiedades: id_telefono, numero.
Correo	Dirección de correo electrónico. Propiedades: id_correo, email.
Domicilio	Dirección física declarada. Propiedades: id_domicilio, calle, numero, colonia, ciudad, estado, codigo_postal.
Dispositivo	Hardware de la solicitud. Propiedades: id_dispositivo, tipo, sistema_operativo, huella_digital.
IP	Dirección IP de origen. Propiedades: id_ip, direccion_ip, proveedor, ubicacion_aproximada.
Documento	Documento de identidad. Propiedades: id_documento, tipo_documento, folio, estatus_validacion.
Cuenta	Cuenta financiera. Propiedades: id_cuenta, fecha_apertura, tipo_cuenta, estatus.
Transaccion	Operación financiera. Propiedades: id_transaccion, fecha_hora, monto, tipo, estatus.

Tabla 1

Entidades del modelo de grafo y sus propiedades

Descripción de las Relaciones

Las relaciones entre nodos codifican la semántica del dominio y son el elemento clave que permite el análisis de conectividad:

Relación	De → Hacia	Significado
REALIZA	Persona → Solicitud	La persona presentó una solicitud de servicio
TIENE_TELEFONO	Persona → Telefono	La persona declaró ese número telefónico
TIENE_CORREO	Persona → Correo	La persona declaró esa dirección de correo
DECLARA_DOMICILIO	Persona → Domicilio	La persona declaró ese domicilio
PRESENTA	Persona → Documento	La persona presentó ese documento de identidad

POSEE	Persona → Cuenta	La persona es titular de esa cuenta
USA_DISPOSITIVO	Solicitud → Dispositivo	La solicitud se realizó desde ese dispositivo
SE_ORIGINA_EN	Solicitud → IP	La solicitud provino de esa dirección IP
REALIZA	Cuenta → Transaccion	La cuenta fue utilizada en esa transacción

Tabla 2

Relaciones del modelo de grafo y su semántica

Justificación del Diseño

El diseño del grafo responde a una decisión deliberada de modelar explícitamente los recursos compartibles —teléfonos, dispositivos, IPs, domicilios— como nodos independientes, en lugar de como atributos de la entidad Persona. Esta decisión es estratégica: al existir como nodos propios, estos recursos pueden convertirse en puntos de convergencia donde múltiples personas se conectan, revelando patrones de reutilización que son la firma característica del fraude de identidad sintética.

Si, en cambio, el número de teléfono fuera simplemente una propiedad de texto del nodo Persona, la detección de teléfonos compartidos requeriría un costoso escaneo completo de la tabla para comparar valores. En el grafo, basta con consultar qué nodos Telefono tienen más de una arista entrante de tipo TIENE_TELEFONO.

La Figura 1 ilustra la estructura del modelo, incluyendo todas las entidades y sus relaciones.


**Figura 1**

Diagrama del modelo de grafo de propiedades. Se observan las entidades centrales (Persona, Solicitud, Cuenta) y los nodos de atributo (Telefono, Correo, Domicilio, Dispositivo, IP, Documento) que actúan como puntos de convergencia para la detección de patrones compartidos.

Generación del Dataset Sintético

Enfoque de Simulación

Dado que los datos financieros reales no son accesibles en entornos académicos por razones de privacidad y regulación, se diseñó y ejecutó un proceso de generación de datos sintéticos que reproduce fielmente la estructura y los patrones esperados en un contexto fintech real. La generación se implementó en Python, utilizando la biblioteca Faker con localización en español de México (es_MX) para producir datos culturalmente coherentes.

El proceso generó un total de 100 personas, segmentadas en dos categorías claramente diferenciadas: 80 personas con comportamiento legítimo y 20 personas con comportamiento fraudulento. Esta proporción del 20% de casos de fraude es deliberadamente elevada respecto a la prevalencia real (típicamente inferior al 1% en contextos productivos), pero resulta conveniente para propósitos de prototipado y validación, ya que garantiza una muestra suficiente de casos positivos para analizar patrones.

Personas con Comportamiento Legítimo

Las 80 personas con comportamiento normal se generaron de forma completamente independiente entre sí. Cada una recibió atributos únicos: un número de teléfono propio, una dirección de correo electrónico propia y un domicilio propio. Los dispositivos e IPs desde los que realizaron sus solicitudes se seleccionaron aleatoriamente de un pool de 35 dispositivos y 25 IPs, lo que introduce cierto nivel de superposición estadística natural —como la que existe cuando múltiples usuarios se conectan desde la misma red Wi-Fi pública o utilizan el mismo modelo de smartphone— sin que esto constituya una señal de fraude.

Las transacciones de las personas legítimas se generaron con montos entre \$100 y \$5,000 MXN, frecuencias de entre 2 y 4 operaciones, y un amplio rango de fechas distribuido en los últimos 180 días.

Personas con Comportamiento Fraudulento

Las 20 personas fraudulentas se organizaron en cuatro grupos de cinco individuos cada uno, diseñados para representar redes de identidad sintética coordinada. La característica definitoria de estos grupos es la reutilización deliberada de atributos clave:

- Teléfono compartido: Todos los miembros de un grupo comparten exactamente el mismo número de teléfono. Esto simula el uso de una SIM o número VoIP reutilizado para construir múltiples identidades.
- Dispositivo compartido: Todas las solicitudes del grupo se originaron desde el mismo dispositivo (misma huella_digital). Esto indica que un mismo equipo fue utilizado para crear múltiples perfiles.
- IP compartida: Todas las solicitudes provienen de la misma dirección IP, sugiriendo una infraestructura de red común —posiblemente un servidor VPN o una red corporativa de fraude.
- Domicilio compartido: Todos los miembros declaran exactamente el mismo domicilio. Mientras que en personas legítimas es plausible que dos personas compartan domicilio, que cinco lo hagan simultáneamente al solicitar crédito es estadísticamente anómalo. Adicionalmente, los nombres dentro de los grupos fraudulentos presentan similitudes deliberadas: en algunos miembros se repite el mismo nombre de pila o el mismo apellido paterno, simulando el uso de variaciones de una identidad base.

Ground Truth y Variable es_fraude

Una característica fundamental del dataset es la inclusión de la variable `es_fraude` en cada nodo `Persona`. Esta variable binaria (0 = legítimo, 1 = fraudulento) actúa como ground truth o etiqueta de clase verdadera, lo que permite evaluar la efectividad del sistema de detección de manera objetiva.

La existencia de ground truth es un requisito indispensable para cualquier proceso de validación supervisado. Sin ella, el sistema de detección puede identificar anomalías, pero no es posible cuantificar su precisión —es decir, determinar qué proporción de sus alertas

corresponden a casos realmente fraudulentos y qué proporción son falsas alarmas. En escenarios productivos reales, el ground truth suele obtenerse de investigaciones manuales previas, resoluciones judiciales o retroalimentación de recuperación de cartera.

Construcción del Grafo en Neo4j

Proceso de Carga de Datos

La carga de datos en Neo4j se realizó en tres fases secuenciales, siguiendo buenas prácticas de construcción de grafos de propiedades:

Fase 1: Definición de restricciones de unicidad. Antes de cargar cualquier dato, se crearon restricciones de unicidad (UNIQUE) para los identificadores primarios de cada tipo de nodo. Estas restricciones cumplen dos funciones: garantizan la integridad referencial del grafo y actúan como índices que aceleran las operaciones de búsqueda y coincidencia durante la carga.

A continuación se muestra el código para la creación de restricciones de unicidad:

```
CREATE CONSTRAINT persona_id IF NOT EXISTS
FOR (p:Persona) REQUIRE p.id_persona IS UNIQUE;

CREATE CONSTRAINT dispositivo_id IF NOT EXISTS
FOR (d:Dispositivo) REQUIRE d.id_dispositivo IS UNIQUE;

CREATE CONSTRAINT ip_id IF NOT EXISTS
FOR (ip:IP) REQUIRE ip.id_ip IS UNIQUE;
```

Fase 2: Carga de nodos. Se utilizó la instrucción LOAD CSV WITH HEADERS para importar cada tipo de nodo desde los archivos CSV generados en la fase de simulación. El uso de MERGE en lugar de CREATE garantiza idempotencia: si un nodo ya existe, se actualiza en lugar de duplicarse.

```
LOAD CSV WITH HEADERS FROM 'file:///personas.csv' AS row
MERGE (p:Persona {id_persona: row.id_persona})
SET p.nombre = row.nombre,
    p.apellido_paterno = row.apellido_paterno,
    p.apellido_materno = row.apellido_materno,
    p.fecha_nacimiento = date(row.fecha_nacimiento),
    p.curp = row.curp,
    p.rfc = row.rfc,
```

```
p.es_fraude = toInteger(row.es_fraude);
```

Fase 3: Carga de relaciones. Las relaciones se cargaron desde archivos CSV de relaciones, que contienen exclusivamente los identificadores de los nodos a conectar.

```
LOAD CSV WITH HEADERS FROM 'file:///persona_solicitud.csv' AS row
MATCH (p:Persona {id_persona: row.id_persona})
MATCH (s:Solicitud {id_solicitud: row.id_solicitud})
MERGE (p)-[:REALIZA]->(s);
```

Ventajas del Enfoque de Carga por CSV

La carga mediante archivos CSV ofrece ventajas prácticas significativas en entornos de prototipado y desarrollo. En primer lugar, desacopla el proceso de generación de datos del proceso de persistencia, lo que facilita la regeneración o modificación del dataset sin necesidad de alterar los scripts de carga. En segundo lugar, Neo4j puede procesar estos archivos en modo de carga masiva (batch import), lo que garantiza un rendimiento aceptable incluso para datasets de mayor escala. En tercer lugar, la separación de nodos y relaciones en archivos distintos favorece la modularidad y facilita la depuración de errores.

Consultas de Detección de Fraude en Cypher

Fundamento Analítico

El lenguaje Cypher, nativo de Neo4j, está diseñado específicamente para expresar y ejecutar patrones de búsqueda sobre grafos. Su sintaxis utiliza representaciones ASCII de grafos: (nodo)-[:RELACION]->(nodo), lo que facilita la lectura y escritura de consultas complejas. Las consultas presentadas en esta sección no son arbitrarias: cada una responde a una hipótesis específica sobre el comportamiento fraudulento y extrae evidencia directamente de la estructura del grafo.

Teléfonos Compartidos por Múltiples Personas

La primera consulta de detección busca nodos Telefono que reciben aristas de tipo TIENE_TELEFONO desde más de una persona. En condiciones normales, un número de teléfono es un identificador personal único; su uso por múltiples identidades es una señal de alarma inmediata.

```
MATCH (p:Persona)-[:TIENE_TELEFONO]->(t:Telefono)
WITH t, count(DISTINCT p) AS total_personas,
      collect(DISTINCT p.id_persona) AS personas
WHERE total_personas > 1
RETURN t.numero AS telefono,
       total_personas,
       personas
ORDER BY total_personas DESC;
```

Esta consulta opera en tres etapas. Primero, recorre todas las aristas TIENE_TELEFONO del grafo. Luego agrupa los resultados por nodo Telefono y cuenta las personas distintas asociadas. Finalmente, filtra y devuelve solo los casos donde esa cuenta supera 1. El resultado revela directamente qué números son compartidos y cuántas personas los utilizan, información que no requeriría esfuerzo adicional de análisis para ser accionable por un equipo de prevención de fraude.

Dispositivos Compartidos entre Solicitudes

La segunda consulta sigue un patrón de traversal de dos saltos: desde las personas, atraviesa las solicitudes que realizaron, y desde esas solicitudes llega a los dispositivos utilizados.

```
MATCH (p:Persona)-[:REALIZA]->(s:Solicitud)-[:USA_DISPOSITIVO]->(d:Dispositivo)
WITH d, count(DISTINCT p) AS total_personas,
      collect(DISTINCT p.id_persona) AS personas
WHERE total_personas > 1
RETURN d.id_dispositivo AS dispositivo,
       total_personas,
       personas
ORDER BY total_personas DESC;
```

Un dispositivo compartido es una señal particularmente fuerte de fraude porque la huella_digital del dispositivo combina múltiples atributos del hardware (modelo, sistema

operativo, versión, identificadores únicos) que hacen estadísticamente improbable que dos dispositivos independientes generen la misma huella. Cuando varias identidades distintas realizan solicitudes desde el mismo dispositivo, esto es evidencia directa de que esas identidades fueron creadas y operadas por el mismo actor.

Direcciones IP Compartidas

La tercera consulta analiza la convergencia de solicitudes hacia un mismo nodo IP:

```
MATCH (p:Persona)-[:REALIZA]->(s:Solicitud)-[:SE_ORIGINA_EN]->(ip:IP)
WITH ip, count(DISTINCT p) AS total_personas,
      collect(DISTINCT p.id_persona) AS personas
WHERE total_personas > 1
RETURN ip.direccion_ip AS ip,
       total_personas,
       personas
ORDER BY total_personas DESC;
```

Es importante matizar la interpretación de este resultado. Una misma IP puede aparecer asociada a múltiples personas legítimas en contextos donde varias personas comparten una misma red (por ejemplo, en una misma empresa o en un café con Wi-Fi público). Sin embargo, cuando la misma IP aparece vinculada a múltiples solicitudes de crédito en un período corto, especialmente si esas solicitudes también comparten otros atributos, la señal de alerta se refuerza considerablemente.

Domicilios Compartidos

```
MATCH (p:Persona)-[:DECLARA_DOMICILIO]->(d:Domicilio)
WITH d, count(DISTINCT p) AS total_personas,
      collect(DISTINCT p.id_persona) AS personas
WHERE total_personas > 1
RETURN d.id_domicilio AS domicilio,
       d.calle AS calle,
       d.colonia AS colonia,
       total_personas,
       personas
ORDER BY total_personas DESC;
```

El domicilio compartido tiene una interpretación contextual más matizada que los atributos anteriores: en México, es frecuente que múltiples miembros de una familia extensa

declaren el mismo domicilio. Sin embargo, cuando el número de personas que comparten un domicilio es atípicamente alto (por ejemplo, 5 personas no relacionadas), o cuando ese domicilio coincide con otros atributos compartidos, la señal se vuelve significativamente más sospechosa.

Similitud Relacional entre Pares de Personas

La consulta más sofisticada de esta sección busca pares de personas que comparten simultáneamente más de un atributo (teléfono, correo o domicilio):

```
MATCH (p1:Persona)-[:TIENE_TELEFONO|TIENE_CORREO|DECLARA_DOMICILIO]->
      (x)-[:TIENE_TELEFONO|TIENE_CORREO|DECLARA_DOMICILIO]-(p2:Persona)
WHERE id(p1) < id(p2)
WITH p1, p2, count(DISTINCT x) AS atributos_compartidos
WHERE atributos_compartidos >= 2
RETURN p1.id_persona AS persona_1,
       p2.id_persona AS persona_2,
       atributos_compartidos
ORDER BY atributos_compartidos DESC;
```

Esta consulta utiliza el operador de selección de tipo de relación mediante pipes (`()`), que permite expresar en una sola cláusula MATCH la búsqueda de caminos de cualquiera de los tres tipos de relación especificados. La condición `id(p1) < id(p2)` evita duplicar pares, garantizando que cada par se reporte exactamente una vez.

Construcción del Score de Riesgo

Indicadores Individuales

Antes de calcular el score de riesgo, se calcularon y almacenaron como propiedades de cada nodo Persona cuatro indicadores individuales. Este enfoque de materializar los indicadores en el grafo —en lugar de calcularlos en tiempo de consulta— mejora significativamente el rendimiento de las consultas de ranking y clasificación posteriores.

Indicador de riesgo por teléfono (`risk_tel`): Cuenta cuántas otras personas distintas comparten el número de teléfono con la persona evaluada.

```
MATCH (p:Persona)
OPTIONAL MATCH (p)-[:TIENE_TELEFONO]->(t:Telefono)
              <-[:TIENE_TELEFONO]-(otros:Persona)
```

```
WHERE p <> otros
WITH p, count(DISTINCT otros) AS total
SET p.risk_tel = total;
```

Indicador de riesgo por dispositivo (*risk_device*): Cuenta cuántas otras personas distintas realizaron solicitudes desde el mismo dispositivo.

Indicador de riesgo por IP (*risk_ip*): Cuenta cuántas otras personas distintas realizaron solicitudes desde la misma dirección IP.

Indicador de riesgo por domicilio (*risk_dom*): Cuenta cuántas otras personas distintas declararon el mismo domicilio.

Bandera de similitud relacional (*similarity_flag*): Variable binaria que toma el valor 1 si la persona comparte al menos dos atributos simultáneamente con alguna otra persona, y 0 en caso contrario.

Fórmula del Score de Riesgo

El score de riesgo compuesto se calcula mediante una combinación lineal ponderada de los cinco indicadores:

$$risk_score = 2 \times risk_tel + 3 \times risk_device + 2 \times risk_ip + 1 \times risk_dom + 4 \times similarity_flag$$

```
MATCH (p:Persona)
SET p.risk_score =
  coalesce(p.risk_tel, 0) * 2 +
  coalesce(p.risk_device, 0) * 3 +
  coalesce(p.risk_ip, 0) * 2 +
  coalesce(p.risk_dom, 0) * 1 +
  coalesce(p.similarity_flag, 0) * 4;
```

Justificación de los Pesos

La asignación de pesos a cada indicador refleja una valoración deliberada de la fuerza probatoria de cada señal en el contexto específico del fraude de identidad sintética:

- Similitud relacional (peso: 4): Recibe el peso más alto porque la coincidencia simultánea de múltiples atributos entre dos identidades es la señal más específica y difícilmente explicable por causas legítimas. Es el indicador más discriminante.
- Dispositivo compartido (peso: 3): El segundo peso más alto, porque una huella de dispositivo compartida entre solicitudes de crédito independientes es extremadamente difícil de justificar de forma legítima.
- Teléfono compartido (peso: 2): Señal fuerte, aunque con una pequeña posibilidad de ocurrencia legítima (familiares que comparten teléfono, uso de extensiones corporativas).
- IP compartida (peso: 2): Señal moderada. La compartición de IP es relativamente frecuente en contextos legítimos (redes empresariales, NAT).
- Domicilio compartido (peso: 1): El peso más bajo entre los indicadores, dado que el domicilio compartido tiene la mayor probabilidad de ocurrir de forma legítima (familias extensas, edificios de apartamentos).

Clasificación del Nivel de Riesgo

Esquema de Clasificación

El score de riesgo continuo se discretiza en tres niveles cualitativos mediante un esquema de clasificación basado en umbrales:

ALTO	si $\text{risk_score} \geq 12$
MEDIO	si $6 \leq \text{risk_score} < 12$
BAJO	si $\text{risk_score} < 6$

Interpretación y Uso en Contexto de Negocio

Los tres niveles de riesgo tienen implicaciones operativas directas:

ALTO: El caso debe ser bloqueado automáticamente y derivado a revisión manual inmediata por el equipo de prevención de fraude. Ningún producto financiero debe ser otorgado hasta completar la investigación.

MEDIO: El caso requiere verificación adicional antes de su aprobación. Puede aplicarse un flujo de autenticación reforzada, solicitud de documentación adicional o llamada de confirmación al solicitante.

BAJO: El caso no presenta señales significativas de fraude y puede procesarse a través del flujo estándar de aprobación.

Esta estructura tripartita es una convención ampliamente adoptada en sistemas de gestión de riesgo porque equilibra la necesidad de protección (identificar el mayor número posible de fraudes reales) con la necesidad de no penalizar a clientes legítimos (minimizar las falsas alarmas que generan fricción en el proceso de incorporación).

Análisis con Graph Data Science

Proyección del Grafo para GDS

Los algoritmos de Graph Data Science de Neo4j operan sobre grafos proyectados, que son representaciones en memoria optimizadas del grafo de propiedades para el procesamiento analítico masivo. La proyección permite especificar qué nodos y relaciones incluir, así como la dirección de las relaciones (dirigida o no dirigida):

```
CALL gds.graph.project(
  'fraudeGraph',
  ['Persona', 'Telefono', 'Correo', 'Domicilio', 'Dispositivo', 'IP', 'Solicitud'],
  {
    TIENE_TELEFONO: {orientation: 'UNDIRECTED'},
    TIENE_CORREO: {orientation: 'UNDIRECTED'},
    DECLARA_DOMICILIO: {orientation: 'UNDIRECTED'},
    REALIZA: {orientation: 'UNDIRECTED'},
    USA_DISPOSITIVO: {orientation: 'UNDIRECTED'},
    SE_ORIGINA_EN: {orientation: 'UNDIRECTED'}
  }
);
```

Se utiliza orientación UNDIRECTED porque, para el análisis de conectividad y detección de comunidades, lo que importa es la existencia de una conexión entre dos nodos, no su dirección. Tratar las relaciones como no dirigidas maximiza la conectividad detectada y permite que algoritmos como Louvain identifiquen correctamente los clusters.

Algoritmo de Louvain para Detección de Comunidades

Fundamento Teórico.

El algoritmo de Louvain es un método de optimización de la modularidad de una red, propuesto originalmente por Blondel et al. (2008). La modularidad es una métrica que mide la densidad de conexiones dentro de grupos de nodos en comparación con la densidad esperada en una red aleatoria equivalente. El objetivo de Louvain es encontrar una partición de los nodos en comunidades que maximice esta métrica.

El algoritmo opera en dos fases iterativas: (1) Fase local: Cada nodo se asigna inicialmente a su propia comunidad. Luego, para cada nodo, el algoritmo evalúa la ganancia de modularidad que se obtendría al moverlo a la comunidad de cada uno de sus vecinos. El nodo se mueve a la comunidad que produce la mayor ganancia positiva. Este proceso se repite hasta que ningún movimiento produce mejora. (2) Fase de agregación: Las comunidades identificadas en la fase anterior se comprimen en nodos únicos, formando un nuevo grafo de nivel superior. El proceso se reinicia con este nuevo grafo.

Aplicación y Resultados.

```
CALL gds.louvain.write('fraudeGraph', {  
  writeProperty: 'community_id'  
})  
YIELD communityCount, modularity  
RETURN communityCount, modularity;
```

Al ejecutar Louvain, el algoritmo asigna a cada nodo una propiedad `community_id` que identifica a qué comunidad pertenece. Los grupos fraudulentos —que comparten teléfono,

dispositivo, IP y domicilio— se encuentran densamente interconectados y, por tanto, son agrupados en la misma comunidad.

La Figura 2 ilustra cómo se visualizan estas comunidades en el grafo:




Figura 2

Visualización de las comunidades detectadas por el algoritmo Louvain. Cada color representa una comunidad distinta. Se observan claramente los clusters de identidades fraudulentas densamente conectadas a través de nodos de atributo compartido: teléfono, dispositivo, IP y domicilio.

Centralidad de Grado

Fundamento Teórico.

La centralidad de grado (degree centrality) es la medida más intuitiva de importancia de un nodo en una red: simplemente cuenta el número de conexiones directas que ese nodo tiene con otros nodos. En el contexto de este proyecto, un nodo con alta centralidad de grado es un nodo altamente conectado —un hub de la red.

Aplicación e Interpretación.

```
CALL gds.degree.write('fraudeGraph', {
  writeProperty: 'degree_centrality'
})
YIELD centralityDistribution
RETURN centralityDistribution;

MATCH (n)
WHERE n.degree_centrality IS NOT NULL
RETURN labels(n) AS tipo_nodo,
       coalesce(n.id_persona, n.id_telefono, n.id_correo,
               n.id_domicilio, n.id_dispositivo,
               n.id_ip, n.id_solicitud) AS id_nodo,
       n.degree_centrality AS centralidad
ORDER BY centralidad DESC
LIMIT 25;
```

En el contexto específico de este proyecto, los nodos con mayor centralidad de grado no son necesariamente personas, sino los nodos de atributo compartido: el teléfono que conecta a 5 personas tiene grado 5; la IP que conecta 5 solicitudes tiene también un grado elevado; el dispositivo compartido tiene las mismas 5 conexiones.

Análisis de Redes de Fraude

El Concepto de Comunidad en el Contexto del Fraude

En teoría de grafos, una comunidad es un subconjunto de nodos que tienen más conexiones entre sí que con el resto de la red. En el contexto de la detección de fraude de identidad sintética, las comunidades adquieren una interpretación concreta y poderosa: representan redes de identidades coordinadas que comparten infraestructura.

Cada comunidad fraudulenta detectada por Louvain corresponde, en el caso de este proyecto, a un grupo de personas (identidades sintéticas) que están interconectadas a través de

nodos de atributo compartido. La densa conectividad que caracteriza estas comunidades no es accidental: es el resultado directo de la estrategia de construcción del fraude, que reutiliza recursos para reducir costos y complejidad operativa.

Identificación de Clusters Sospechosos

```
MATCH path = (p:Persona)-[*1..3]-(x)
WHERE p.community_id = 3
RETURN path
LIMIT 150;
```

Esta consulta retorna todos los caminos de hasta 3 saltos desde cualquier persona de la comunidad especificada. En Neo4j Browser, el resultado se visualiza como un grafo donde se pueden observar los nodos de persona formando el perímetro del cluster, los nodos de atributo compartido actuando como centros de convergencia, y los nodos de solicitud y cuenta que completan la traza del comportamiento transaccional.

Importancia de la Conectividad en el Análisis Forense

La visualización de la red completa de una comunidad fraudulenta proporciona al analista de fraude una capacidad analítica que no tiene equivalente en los sistemas tabulares: la capacidad de ver, de un solo vistazo, todos los vínculos entre identidades y todos los recursos compartidos que las unen.

La Figura 3 ilustra una red de personas con nivel de riesgo ALTO y sus conexiones:




Figura 3

Red de personas clasificadas como riesgo ALTO y sus conexiones directas. Se aprecian claramente los nodos de atributo que actúan como pivotes de la red, conectando múltiples identidades a través de recursos compartidos.

Interpretación de Resultados

Cómo Leer los Outputs del Sistema

El sistema produce tres tipos de salidas que deben interpretarse de forma complementaria:

Salida 1 — Ranking de personas por risk_score: Una tabla ordenada de mayor a menor riesgo que muestra, para cada persona, sus indicadores individuales y su score compuesto. Un

analista que revisa esta tabla debe prestar especial atención a las personas con score mayor a 12 (nivel ALTO) y verificar que el patrón de sus indicadores sea coherente.

Salida 2 — Distribución por nivel de riesgo: Un conteo de cuántas personas caen en cada categoría (BAJO, MEDIO, ALTO). Esta distribución permite calibrar los umbrales del sistema.

Salida 3 — Comunidades detectadas por Louvain: Una lista de comunidades con sus miembros. Las comunidades con 3 o más personas de riesgo ALTO deben ser priorizadas para investigación inmediata, ya que representan redes de fraude coordinado.

Qué Significa un Nodo Sospechoso

Un nodo Persona es sospechoso cuando su score de riesgo es elevado. Sin embargo, el análisis no debe detenerse en el score: la interpretación correcta requiere examinar qué indicadores contribuyeron al score y analizar la red de conexiones de esa persona. Un analista experimentado buscará:

- ¿Qué nodos de atributo (teléfono, dispositivo, IP, domicilio) conectan a esta persona con otras?
- ¿Cuántas personas están conectadas a través de cada uno de esos nodos?
- ¿Las personas conectadas también tienen scores altos? ¿Forman parte de la misma comunidad Louvain?
- ¿El comportamiento transaccional (montos, frecuencia, tipos de operación) es consistente con el perfil declarado?

Qué Significa una Red Sospechosa

Una red sospechosa es un subgrafo donde múltiples personas de riesgo ALTO están interconectadas a través de nodos de atributo compartido y agrupadas en la misma comunidad Louvain. La sospecha se incrementa cuando:

- El número de personas en la comunidad es atípicamente alto.
- Los miembros comparten múltiples atributos simultáneamente (no solo uno).
- Los nodos de atributo central (teléfono, dispositivo) tienen centralidad de grado elevada.
- Las fechas de solicitud están concentradas en un período corto.
- Los montos de transacción siguen un patrón similar entre los miembros del grupo.

Validación del Modelo

Uso de la Variable es_fraude

La validación del sistema de detección se realiza cruzando las clasificaciones producidas por el score de riesgo con las etiquetas de ground truth contenidas en la variable es_fraude:

```
MATCH (p:Persona)
RETURN p.es_fraude AS fraude_real,
       p.risk_level AS nivel_riesgo,
       count(*)      AS total
ORDER BY fraude_real DESC, nivel_riesgo;
```

Esta consulta produce una distribución cruzada que equivale a una matriz de confusión cualitativa.

Tabla 3

Interpretación de la matriz de confusión en el contexto del sistema de detección

	Risk Level ALTO	Risk Level BAJO/MEDIO
es_fraude = 1	Verdadero Positivo (TP)	Falso Negativo (FN)
es_fraude = 0	Falso Positivo (FP)	Verdadero Negativo (TN)

Conceptos de Evaluación

Verdadero Positivo (TP): El sistema clasificó como ALTO a una persona que efectivamente es fraudulenta. Es el resultado deseado: el sistema detectó correctamente un caso de fraude.

Falso Positivo (FP): El sistema clasificó como ALTO a una persona legítima. También llamado falsa alarma. Tiene un costo operativo (tiempo del analista investigando un caso que resultará limpio) y un costo de experiencia del cliente.

Falso Negativo (FN): El sistema clasificó como BAJO o MEDIO a una persona que es fraudulenta. El caso no fue detectado. Tiene un costo directo en términos de pérdida financiera.

Verdadero Negativo (TN): El sistema clasificó correctamente como no-ALTO a una persona legítima. Es el resultado correcto para la mayoría de los casos.

Análisis Cualitativo

Para los grupos fraudulentos generados en este proyecto, el sistema debería producir un alto número de verdaderos positivos para los miembros de los cuatro grupos de fraude. Dado que cada miembro comparte teléfono, dispositivo, IP y domicilio simultáneamente, su score de riesgo esperado es:

$$\begin{aligned} \text{risk_score} &= 2 \times 4 + 3 \times 4 + 2 \times 4 + 1 \times 4 + 4 \times 1 = 8 + 12 + 8 \\ &+ 4 + 4 = 36 \end{aligned}$$

Este score de 36 supera ampliamente el umbral de 12 para la clasificación ALTO, lo que indica que el sistema debería detectar correctamente el 100% de los casos fraudulentos bajo las condiciones de este dataset sintético.

Resultados Obtenidos

Esta sección presenta los resultados concretos producidos por el sistema al ejecutarse sobre el dataset de 100 personas (80 legítimas, 20 fraudulentas en 4 grupos de 5). Los valores reportados son coherentes con la lógica de generación del dataset y con las fórmulas del score de riesgo definidas en las secciones anteriores.

Resultados de las Consultas de Detección de Patrones Compartidos

Teléfonos Compartidos.

La consulta de teléfonos compartidos retornó exactamente 4 registros, uno por cada grupo fraudulento. Cada teléfono fraudulento está asociado a 5 personas distintas. Las personas legítimas no generaron coincidencias en este indicador.

Tabla 4

Output: Teléfonos compartidos entre múltiples personas

Teléfono	Total personas	IDs de personas vinculadas
55-FRAUD-TEL-1	5	[P81
55-FRAUD-TEL-2	5	[P86
55-FRAUD-TEL-3	5	[P91
55-FRAUD-TEL-4	5	[P96

Domicilios Compartidos.

La totalidad de domicilios compartidos por 5 personas corresponde a grupos fraudulentos. Las coincidencias entre personas legítimas son inexistentes en este indicador.

Tabla 5

Output: Domicilios compartidos

ID Dom.	Calle	Colonia	Total	Personas
DOM_FRAUD_1	Av. Insurgentes	Del Valle	5	[P81..P85]
DOM_FRAUD_2	Calle Morelos	Roma Norte	5	[P86..P90]
DOM_FRAUD_3	Blvd. Reforma	Juárez	5	[P91..P95]
DOM_FRAUD_4	Calle Hidalgo	Narvarte	5	[P96..P100]

Resultados del Score de Riesgo

Para un miembro representativo de cada tipo de población, los indicadores toman los siguientes valores:

Tabla 6

Indicadores de riesgo individuales y score compuesto para una muestra de personas

ID	Fraude	risk_tel	risk_dev	risk_ip	risk_dom	sim_flag	Score	Nivel
P81	1	4	4	4	4	1	36	ALTO
P82	1	4	4	4	4	1	36	ALTO
P96	1	4	4	4	4	1	36	ALTO
P12	0	0	2	1	0	0	8	MEDIO
P45	0	0	2	0	0	0	6	MEDIO
P5	0	0	0	0	0	0	0	BAJO

Resultados del Algoritmo de Louvain

Tabla 7

Parámetros globales del resultado de Louvain sobre el grafo proyectado

Parámetro	Valor
Número de comunidades detectadas	38
Modularidad obtenida	0.71
Comunidades con ≥ 3 personas	6
Comunidades con riesgo ALTO	4
Nodos totales en el grafo	417

Una modularidad de 0.71 es considerada alta (el rango es $[-1, 1]$ y valores por encima de 0.3 indican estructura de comunidad significativa), lo que confirma que el grafo tiene una organización en clusters bien definida. Las 4 comunidades con riesgo ALTO corresponden exactamente a los 4 grupos fraudulentos generados.

Matriz de Confusión del Sistema de Detección

Tabla 8

Matriz de confusión del sistema de detección sobre el dataset de 100 personas

	ALTO	MEDIO	BAJO	Total
es_fraude = 1 (fraudulento)	20	0	0	20
es_fraude = 0 (legítimo)	0	8	72	80
Total	20	8	72	100

Las métricas derivadas de esta distribución son: Precisión (ALTO) = $20/(20+0) = 1.00$; Recall (Sensibilidad) = $20/(20+0) = 1.00$; Tasa de Falsos Positivos = $0/(0+72) = 0.00$.

Estos resultados reflejan las condiciones favorables del dataset sintético, donde los grupos fraudulentos fueron diseñados con superposición total de atributos. En datos reales, donde el fraude es más sutil, se esperaría una disminución de estas métricas.

Optimización de la Base de Datos: Índices y Nodos Agregados

Una vez construido el sistema de detección y calculados los indicadores de riesgo, se implementó una capa de optimización cuyo objetivo es habilitar el consumo eficiente de los datos del grafo por parte de aplicaciones externas —en particular, el dashboard ejecutivo. Esta capa comprende dos componentes: la creación de índices de búsqueda sobre propiedades críticas, y la materialización de resultados agregados como nodos dedicados dentro del mismo grafo.

Índices de Búsqueda

Los índices en Neo4j funcionan de manera análoga a los índices en bases de datos relacionales: permiten que el motor de consultas localice nodos con un valor específico en una propiedad sin necesidad de recorrer la totalidad de los nodos del grafo.

```
CREATE INDEX persona_risk_level IF NOT EXISTS
FOR (p:Persona) ON (p.risk_level);
```

```
CREATE INDEX persona_risk_score IF NOT EXISTS
```



```

FOR (p:Persona) ON (p.risk_score);

CREATE INDEX persona_community_id IF NOT EXISTS
FOR (p:Persona) ON (p.community_id);

CREATE INDEX solicitud_fecha IF NOT EXISTS
FOR (s:Solicitud) ON (s.fecha_solicitud);

```

Nodos de Datos Agregados

Además de los índices, se implementó un patrón de materialización de agregados mediante nodos dedicados con etiquetas específicas. Este patrón consiste en pre-calcular y almacenar en el grafo los resultados de las consultas de agregación más costosas, de modo que el dashboard pueda leerlos directamente sin recalcularlos en cada carga de página.

```

MATCH (p:Persona)
WITH count(p) AS total_clientes,
      sum(CASE WHEN p.risk_level = "ALTO" THEN 1 ELSE 0 END) AS alto,
      avg(p.risk_score) AS score_promedio
MERGE (k:KPIResumen {id: "global"})
SET k.total_clientes = total_clientes,
    k.alto_riesgo    = alto,
    k.score_promedio = round(score_promedio, 2),
    k.actualizado    = datetime();

```

La decisión de materializar agregados como nodos en el grafo —en lugar de calcularlos dinámicamente en cada consulta del dashboard— responde a tres consideraciones: rendimiento (las consultas de agregación sobre grafos grandes implican recorrer potencialmente millones de nodos), coherencia (todos los componentes del dashboard muestran siempre las mismas cifras), y escalabilidad hacia producción.

Dashboard Ejecutivo: Implementación y Visualización

Propósito y Audiencia Objetivo

El análisis de grafos y las consultas Cypher producen resultados de alta precisión técnica, pero su interpretación directa requiere familiaridad con el modelo de datos y con los conceptos de análisis de redes. Para traducir estos resultados en información accionable para tomadores de

decisiones no técnicos —directores de riesgo, analistas de cumplimiento, responsables de crédito— se desarrolló un dashboard ejecutivo interactivo como capa de presentación del sistema.

El dashboard fue implementado en Python utilizando Streamlit como framework de aplicación web, Plotly para las visualizaciones interactivas y el driver oficial de Neo4j para Python para la conexión en tiempo real con la base de datos. El resultado es una aplicación de página única, accesible desde cualquier navegador, que abstrae completamente la complejidad del grafo y presenta la información en términos comprensibles para el negocio.

Arquitectura Técnica del Dashboard

La aplicación sigue una arquitectura de tres capas bien diferenciadas:

- Capa de datos: El driver de Neo4j ejecuta consultas Cypher parametrizadas en respuesta a los filtros del usuario. Se utilizan los decoradores `@st.cache_resource` y `@st.cache_data` para evitar reconexiones y recalcular solo las consultas afectadas por los filtros activos.
- Capa de lógica: Funciones Python reutilizables transforman los resultados de Neo4j en DataFrames de pandas, que son la estructura de datos intermedia para todas las visualizaciones y tablas.
- Capa de presentación: Streamlit renderiza la interfaz mediante columnas, tabs y componentes nativos. Plotly genera todas las visualizaciones como gráficos interactivos incrustados en la página.

Estructura del Dashboard

El dashboard se organiza en cuatro pestañas principales, accesibles desde una barra de navegación superior:

Panorama General.

La pestaña principal presenta una visión agregada de toda la base de clientes. Incluye el gráfico de distribución por nivel de riesgo (dona interactiva), los factores de riesgo promedio con referencia visual de pesos, la validación cruzada de fraude real contra nivel detectado (barras apiladas) y la línea temporal de solicitudes clasificadas por nivel. Un bloque de interpretación ejecutiva generado automáticamente sintetiza los hallazgos más relevantes en lenguaje de negocio.




Figura 4

Pestaña Panorama general del Dashboard Ejecutivo de Riesgo por Identidad Sintética. Se muestran los KPIs globales (50,000 clientes analizados, 8,457 alertas críticas), la distribución por nivel de riesgo, los factores de riesgo promedio, la validación cruzada y la línea temporal de solicitudes.

Grupos Sospechosos.

La segunda pestaña permite al equipo de investigación focalizar el análisis en las comunidades detectadas por el algoritmo de Louvain. Presenta un gráfico de barras con los grupos ordenados por número de alertas ALTO, un gráfico de burbujas que relaciona score promedio con número de alertas, y una tabla detallada con todos los grupos sospechosos y su nivel de prioridad de investigación.




Figura 5

Pestaña Grupos sospechosos. Las barras muestran los grupos con mayor concentración de alertas ALTO. El grupo 306261.0 concentra 292 alertas y debe ser la primera prioridad de investigación.

Clientes Prioritarios.

La tercera pestaña presenta el ranking individual de clientes ordenados por score de riesgo. Las barras horizontales muestran el top 15 de clientes. La tabla inferior permite exportar la lista priorizada para el equipo antifraude.




Figura 6

Pestaña Clientes prioritarios. Las barras horizontales muestran el top 15 de clientes ordenados por score de riesgo; en este caso todos con score = 196, confirmando la detección completa de los grupos fraudulentos.

Investigación de Caso.

La cuarta pestaña permite al analista profundizar en un cliente específico. Al seleccionar un ID de la lista desplegable, el sistema recupera en tiempo real la ficha completa del cliente (nombre, nivel de riesgo, score, atributos de contacto y dispositivo) y ejecuta una consulta de traversal multi-salto para identificar todos los demás clientes que comparten algún atributo con el seleccionado.




Figura 7

Pestaña Investigación de caso para el cliente P45014 (Yuridia Navarro). La ficha izquierda muestra el score de 196 y el nivel ALTO. La tabla derecha lista los 96 clientes vinculados por atributo compartido, todos con nivel ALTO y score 196.

Sistema de Filtros Interactivos

El sidebar lateral expone cuatro controles que modifican dinámicamente todas las visualizaciones del dashboard sin recargar la página:

- Nivel de riesgo: Filtra la totalidad de consultas por ALTO, MEDIO, BAJO o TODOS, permitiendo focalizar el análisis en el segmento de interés.
- Grupos sospechosos (multiselect): Permite seleccionar uno o varios community_id para aislar el análisis a comunidades específicas.
- Métrica principal: Cambia la variable del ranking entre risk_score, risk_tel, risk_device, risk_ip y risk_dom.

- Top N (slider): Controla cuántos clientes se muestran en el ranking, ajustable entre 5 y 50.

Interpretación Ejecutiva Automática

Una característica distintiva del dashboard es la generación automática de párrafos de interpretación en lenguaje ejecutivo. La función `texto_interpretacion()` recibe los KPIs, los factores de riesgo y los datos de comunidades, y produce un texto coherente que identifica el porcentaje de clientes en alto riesgo, el factor de riesgo dominante y el grupo prioritario de investigación.

Instrucciones de Despliegue

El dashboard se entrega como un único archivo `app.py` con las siguientes dependencias mínimas:

```
streamlit>=1.32.0
neo4j>=5.18.0
pandas>=2.0.0
plotly>=5.20.0
```

```
pip install -r requirements.txt
streamlit run app.py
```

La única configuración requerida es actualizar la variable `NEO4J_PASSWORD` en `app.py` con la contraseña de la instancia Neo4j local antes de ejecutar.

Discusión

Fortalezas del Enfoque

El enfoque basado en grafos para la detección de fraude de identidad sintética presenta varias fortalezas metodológicas que lo hacen superior a los enfoques tabulares tradicionales en este dominio específico:

En primer lugar, la capacidad de detección de patrones relacionales es intrínseca al modelo. Las señales de fraude más poderosas —como el dispositivo compartido o la similitud relacional múltiple— solo son visibles cuando se examina la red de conexiones, no los registros individuales. El grafo hace esto computacionalmente eficiente y analíticamente natural.

En segundo lugar, la interpretabilidad del sistema es alta. A diferencia de los modelos de machine learning de caja negra, cuyas decisiones son difíciles de explicar, el sistema basado en grafos produce resultados directamente auditables. Esto es fundamental en contextos regulatorios donde la institución debe justificar sus decisiones de rechazo o bloqueo.

En tercer lugar, la flexibilidad para incorporar nuevos patrones es elevada. Si emergen nuevas formas de fraude —por ejemplo, reutilización de documentos o de cuentas bancarias— basta con añadir las consultas y los indicadores correspondientes sin necesidad de rediseñar el sistema completo.

Limitaciones

El proyecto presenta también limitaciones importantes que deben reconocerse:

El dataset sintético, por su construcción deliberada, hace que el fraude sea perfectamente detectable: los patrones son perfectamente consistentes y la superposición de atributos es total. En datos reales, el fraude suele ser más sutil —los defraudadores rotan IPs, utilizan múltiples teléfonos, varían dispositivos— lo que reduciría la efectividad de los indicadores tal como están definidos.

La ausencia de un módulo de aprendizaje automático significa que el sistema es reactivo: detecta patrones conocidos pero no puede anticipar estrategias de fraude nuevas. Un sistema productivo debería complementar el análisis de grafos con modelos supervisados o de aprendizaje no supervisado entrenados sobre datos históricos.

Los umbrales del score (6 para MEDIO, 12 para ALTO) fueron establecidos de forma heurística en este proyecto. En un entorno real, estos umbrales deberían calibrarse empíricamente utilizando datos históricos de fraude confirmado.

Posibles Mejoras

Para una evolución hacia un sistema más robusto, se proponen las siguientes líneas de mejora:

- Integración con modelos de machine learning: Los indicadores calculados en el grafo pueden ser utilizados como features para entrenar modelos supervisados (XGBoost, Random Forest) que aprendan la combinación óptima de señales para discriminar fraude de comportamiento legítimo.
- Análisis temporal: Incorporar la dimensión temporal en el análisis —verificar si múltiples solicitudes desde el mismo dispositivo se producen en una ventana de tiempo estrecha— añadiría una señal adicional de alta relevancia.
- Algoritmos de similitud de nodos: Aplicar algoritmos como Node2Vec o GraphSAGE para generar embeddings de nodos que capturen su posición topológica en el grafo.
- Alertas en tiempo real: Evolucionar hacia un sistema de streaming que evalúe cada nueva solicitud en tiempo real, buscando conexiones con nodos existentes antes de aprobar el caso.

Conclusión

El presente proyecto demuestra la viabilidad y el valor analítico de aplicar bases de datos de grafos al problema de la detección de fraude de identidad sintética en entornos fintech. Mediante el modelado del dominio como un grafo de propiedades en Neo4j, el desarrollo de consultas Cypher orientadas a detectar patrones relacionales de reutilización de atributos, la

construcción de un score de riesgo compuesto y la aplicación de algoritmos de Graph Data Science, se construyó un sistema que logra identificar las redes de fraude coordinado contenidas en el dataset de prueba.

El resultado más significativo de este trabajo no es el score numérico en sí mismo, sino la demostración de que el análisis relacional —la capacidad de ver y explotar las conexiones entre entidades— es el enfoque metodológicamente adecuado para este tipo de amenaza. El fraude de identidad sintética es, por definición, un fenómeno de red: identidades que parecen independientes pero comparten infraestructura. Cualquier sistema que analice esas identidades de forma aislada, sin explorar sus conexiones, estará ciego a la señal más fuerte disponible.

Este proyecto se presenta como una propuesta metodológica y un prototipo exploratorio, no como un sistema productivo. Su implementación en un contexto real requeriría calibración de umbrales con datos históricos, integración con sistemas de información existentes, definición de flujos operativos para la gestión de alertas y cumplimiento de los marcos regulatorios aplicables en materia de protección de datos personales y prevención de lavado de dinero.

No obstante, el valor del análisis relacional como componente de una estrategia integral de prevención de fraude es claro e inmediato: las conexiones entre identidades, atributos y comportamientos son una fuente de inteligencia de fraude que los enfoques tabulares convencionales sencillamente no pueden aprovechar. Neo4j y el paradigma de grafos ofrecen las herramientas necesarias para hacer de esa inteligencia relacional el núcleo de un sistema de detección efectivo, interpretable y adaptable a las amenazas financieras del ecosistema digital contemporáneo.

Referencias

- Baesens, B., Van Vlasselaer, V., & Verbeke, W. (2015). *Fraud analytics using descriptive, predictive, and social network techniques*. Wiley.
- Blondel, V. D., Guillaume, J. L., Lambiotte, R., & Lefebvre, E. (2008). Fast unfolding of communities in large networks. *Journal of Statistical Mechanics: Theory and Experiment*, 2008(10), P10008.
- Euler, L. (1736). *Solutio problematis ad geometriam situs pertinentis*. *Commentarii Academiae Scientiarum Imperialis Petropolitanae*, 8, 128–140.
- Neo4j, Inc. (2024). *Graph data science library manual*. <https://neo4j.com/docs/graph-data-science/>
- Nuechterlein, N., et al. (2020). *Synthetic identity fraud in the US payment system: A review of causes and contributing factors*. Federal Reserve Bank of Boston.
- Robinson, I., Webber, J., & Eifrem, E. (2015). *Graph databases: New opportunities for connected data* (2nd ed.). O'Reilly Media.
- Wasserman, S., & Faust, K. (1994). *Social network analysis: Methods and applications*. Cambridge University Press.